



HCM-UTE

TRƯỜNG ĐẠI HỌC

CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH

HCMC University of Technology and Engineering

HỌC PHẦN: TƯƠNG TÁC DỮ LIỆU TRỰC QUAN

Mã học phần: IDVI333677

Giảng viên: Ths. Đoàn Minh Trí

Email liên hệ: doanminhtri@hcmute.edu.vn



TƯƠNG TÁC DỮ LIỆU TRỰC QUAN

CHƯƠNG 9

MÔ HÌNH DỰ BÁO

Từ hồi quy tuyến tính đến hồi quy logistic và trực quan hóa kết quả dự báo...

Từ dữ liệu quan sát → mô hình → trực quan → quyết định



Dữ liệu



Mô hình



Dự báo




Trực quan



Quyết định

LINEAR vs. LOGISTIC REGRESSION





HCM-UTE

CHƯƠNG 9

MỤC TIÊU

Mục tiêu học tập

01 Hiểu khái niệm

Mô tả được dự báo, biến mục tiêu, biến giải thích và vai trò của mô hình dự báo trong trực quan hóa dữ liệu.

02 Hồi quy tuyến tính

Xây dựng, diễn giải và đánh giá mô hình hồi quy tuyến tính; nhận diện các vấn đề thường gặp.

03 Phân loại bằng logistic

Phân biệt logistic với linear regression và thiết lập mô hình dự báo nhị phân.

04 Đọc kết quả qua trực quan hóa

Kết nối mô hình với scatter plot, đường hồi quy, residuals, xác suất dự báo và confusion matrix.

05 Quy trình thực hành

Đi từ chuẩn bị dữ liệu → huấn luyện → dự báo → đánh giá → trực quan hóa → diễn giải.

Trọng tâm của chương: Hiểu mô hình để tạo ra trực quan hóa hỗ trợ ra quyết định, không chỉ “vẽ đẹp”.



HCM-UTE

Nội dung chính

A

Giới thiệu mô hình dự báo

- Khái niệm
- vai trò
- Quy trình

B

Hồi quy tuyến tính

- OLS
- Hệ số
- Residual
- R^2
- Giả định

C

Linear vs. Logistic

- Bản chất
- Đầu ra
- Trường hợp sử dụng

D

Xây dựng Logistic Regression

- Odds
- Logit
- Threshold
- Metrics

Câu hỏi xuyên suốt: Mô hình nói gì về dữ liệu và làm thế nào để truyền đạt kết quả một cách trực quan?



HCM-UTE

1. Mô hình dự báo là gì?

Mô hình dự báo là một hàm hoặc hệ thống quy tắc học từ dữ liệu quá khứ để ước lượng giá trị chưa biết hoặc giá trị trong tương lai.

Biến mục tiêu (Y)

Đại lượng cần dự báo.
Ví dụ: điểm số, doanh thu, xác suất đạt/không đạt.

Biến giải thích (X)

Thông tin dùng để dự báo Y.
Ví dụ: thời gian học, số giờ ngủ, số bài tập.

Đầu ra dự báo $\hat{Y}$ hoặc $\hat{p}$

Giá trị số liên tục hoặc xác suất/lớp phân loại tùy bài toán.

$X \rightarrow$ Mô hình học từ dữ liệu $\rightarrow$ Dự báo Y



HCM-UTE

Từ quan sát quá khứ đến dự báo tương lai

QUAN SÁT

Dữ liệu
lịch sử

HỌC

Tìm quy
luật

DỰ BÁO

Giá trị /
xác suất

NHÌN

Trực quan
hóa

QUYẾT ĐỊNH

Người dùng
hành động


Câu hỏi trực quan quan trọng:

“Mô hình đang nhìn vào đâu — và người dùng cần thấy gì để hiểu kết quả?”

Mô hình dự báo không chỉ tạo ra một con số → nó tạo ra một đối tượng có thể khám phá bằng biểu đồ.



Mô hình dự báo là cầu nối giữa dữ liệu và quyết định



Với Logistic Regression, “y” được thay bằng xác suất $p \in (0,1)$ rồi mới qua threshold τ .



HCM-UTE


Chọn đúng đầu ra: Y đang là “giá trị” hay “nhãn”?

DỰ BÁO GIÁ TRỊ

Ví dụ: điểm số, doanh thu, thời gian

→ Hồi quy tuyến tính

đầu ra liên tục




DỰ BÁO NHÃN

Ví dụ: đạt / chưa đạt, có rủi ro / không

→ Hồi quy Logistic

đầu ra là xác suất → nhãn





Vai trò của mô hình dự báo trong trực quan hóa

Khía cạnh	Ý nghĩa trong trực quan hóa
Mục đích	Trực quan hóa giúp nhìn dữ liệu; mô hình dự báo giúp định lượng quan hệ và ngoại suy.
Tương tác	Người học có thể thay đổi X, threshold hoặc bộ lọc để quan sát Y dự báo thay đổi.
Giải thích	Hệ số, residual và xác suất dự báo tạo thêm ngữ cảnh cho biểu đồ.
Ra quyết định	Từ “điểm dữ liệu đang ở đâu?” đến “điều gì có thể xảy ra nếu X thay đổi?”.

Nguyên tắc Không dùng mô hình để che giấu dữ liệu thô. Luôn cho người xem thấy quan sát thực tế, mức độ bất định và phạm vi dữ liệu mà mô hình được học.



HCM-UTE

Quy trình xây dựng một mô hình dự báo

- 1 Đặt câu hỏi** Y cần dự báo là gì?
- 2 Chuẩn bị dữ liệu** Thiếu dữ liệu, ngoại lệ, mã hóa
- 3 Chọn mô hình** Linear hay Logistic?
- 4 Huấn luyện** Ước lượng tham số từ training set
- 5 Đánh giá** Metrics + kiểm tra giả định
- 6 Trực quan hóa** Dự báo, sai số, độ tin cậy
- 7 Diễn giải** Kết luận trong phạm vi dữ liệu



HCM-UTE

2. Hồi quy tuyến tính (Linear Regression)

$$\hat{Y} = \beta_0 + \beta_1 X$$



$$y_i = \beta_0 + \beta_1 x_i + e_i$$

Mục tiêu: tìm đường thẳng mô tả xu hướng của Y theo X và dùng đường này để dự báo giá trị Y.

β_0 — intercept

Giá trị kỳ vọng của Y khi $x_i = 0$. Chỉ có ý nghĩa khi $x_i = 0$ nằm trong ngữ cảnh hợp lý.

β_1 — slope

Mức thay đổi kỳ vọng của Y khi x_i tăng 1 đơn vị, giữ các yếu tố khác không đổi.

e — residual

Phần sai khác giữa quan sát thực tế và giá trị mô hình dự báo: $e_i = y_i - \hat{y}_i$.

VÍ DỤ

Bài toán: Dự báo Điểm thi môn Học máy ($\hat{Y}$) dựa vào Số giờ ôn tập (X).

Sau khi thu thập dữ liệu từ sinh viên và huấn luyện mô hình Hồi quy tuyến tính, ta thu được phương trình dự báo:

$$\hat{Y} = 3.0 + 0.5 \times X$$



VÍ DỤ

TRONG ĐÓ:

X (Biến độc lập): Số giờ sinh viên dành để ôn tập.

$\hat{Y}$ (Giá trị dự báo): Điểm thi kỳ vọng (thang điểm 10).

$\beta_0 = 3.0$ (Intercept - Hệ số chặn): Sinh viên không ôn tập giờ nào ($X = 0$) thì điểm dự báo nhận được là 3.0 điểm (kiến thức nền sẵn).

$\beta_1 = 0.5$ (Slope - Hệ số góc): Cứ ôn tập thêm 1 giờ (X tăng 1 đơn vị), điểm thi dự báo sẽ tăng thêm 0.5 điểm.

VÍ DỤ

Giả sử sinh viên An ôn tập 10 giờ ($x_{An} = 10$):

1. Mô hình dự báo điểm của An ($\hat{y}_{An}$):

$$\hat{y}_{An} = 3.0 + 0.5 \times 10 = 8.0 \text{ điểm}$$

2. Thực tế bài thi (y_{An}): Ngày thi An làm bài đạt 8.5 điểm.
3. Phần dư / Sai số (e_{An}):

$$e_{An} = y_{An} - \hat{y}_{An} = 8.5 - 8.0 = +0.5 \text{ điểm}$$

VÍ DỤ

$$\hat{Y} = \beta_0 + \beta_1 X$$



$$y_i = \beta_0 + \beta_1 x_i + e_i$$

Mối quan hệ thực tế của An được biểu diễn chính xác theo công thức vế phải:


$$\underbrace{y_{An}}_{8.5} = \underbrace{\beta_0 + \beta_1 x_{An}}_{\hat{y}_{An}=8.0} + \underbrace{e_{An}}_{0.5}$$



HCM-UTE

Đi tìm “đường nét xu hướng” của dữ liệu

Scatter plot + đường xu hướng



Ý tưởng trực quan

Tìm một đường thẳng đi
“qua giữa” đám mây điểm.

$$\hat{Y} = \beta_0 + \beta_1 X$$

β_0 : mức bắt đầu

β_1 : độ dốc — X tăng thì y đổi bao nhiêu

Ta cần đọc được “hướng” và “độ dốc” trước khi
quan tâm đến công thức tối ưu.



Từ dữ liệu đến đường hồi quy: ý tưởng OLS

Ordinary Least Squares (OLS) chọn β_0 và β_1 sao cho tổng bình phương residual là nhỏ nhất.

$$\min \sum_i (y_i - \hat{y}_i)^2 = \min \sum_i (y_i - \beta_0 - \beta_1 x_i)^2$$

Ý nghĩa trực quan:


Loss Function

- Mỗi điểm dữ liệu có một khoảng cách đứng (residual - độ lệch) tới đường hồi quy.
- **Residual dương:** mô hình dự báo thấp hơn quan sát; **residual âm:** mô hình dự báo cao hơn quan sát.
- Bình phương residual làm sai số lớn bị phạt mạnh hơn và tránh triệt tiêu giữa sai số phần dư dương, âm.

Lưu ý: Trong hồi quy tuyến tính, “tốt hơn” phải được hiểu theo tiêu chí định lượng và phạm vi dữ liệu, không chỉ theo cảm quan của biểu đồ.

Đọc đường hồi quy bằng hình học

Residual = quan sát – dự báo



Khoảng cách từ điểm thật đến đường dự báo chính là residual.

$$e_i = y_i - \hat{y}_i$$

- Điểm nằm phía trên đường → residual dương
- Điểm nằm phía dưới đường → residual âm
- Điểm nằm trên đường → residual = 0
- Giá trị tuyệt đối của Residual càng lớn → mô hình càng lệch tại điểm đó

Đây là lý do scatter plot + residual plot quan trọng hơn việc chỉ báo cáo một con số.



Ví dụ 2 — Dự báo điểm số từ thời gian học


Giờ học/tuần (X)	2	4	5	6	8	10
Điểm (Y)	51	60	64	66	75	81

$$\hat{Y} = 44.9 + 3.7X$$

Ta có:

- $\beta_1 \approx 3.7$: thêm 1 giờ học/tuần gắn với khoảng +3.7 điểm dự báo trong mẫu này.
- $\beta_0 \approx 44.9$: giá trị mô hình khi $X = 0$
- Với $X = 7$, $\hat{Y} \approx 70.8$ điểm.

Ví dụ 2: Dự báo điểm số từ thời gian học



Một sinh viên học **8 giờ/tuần** → mô hình dự báo khoảng **74.5 điểm**.

Điểm cần quan sát

- Đám mây điểm có xu hướng tăng.
- Đường dự báo tóm tắt xu hướng.
- Một điểm cá nhân vẫn có sai số.
- Không nên đọc đường thẳng ngoài vùng dữ liệu.



Đánh giá độ phù hợp của mô hình

Chỉ số	Công thức	Ghi chú
MAE	$MAE = (1/n)\Sigma y_i - \hat{y}_i $	Mean Absolute Error - Sai số tuyệt đối trung bình. Dễ diễn giải theo đơn vị của Y.
MSE	$MSE = (1/n)\Sigma(y_i - \hat{y}_i)^2$	Mean Squared Error - Sai số bình phương trung bình. Phạt mạnh sai số lớn.
RMSE	$RMSE = \sqrt{MSE}$	Root Mean Squared Error - Căn bậc hai sai số bình phương trung bình. Cùng đơn vị với Y và rất nhạy với outlier.

Độc độ phù hợp bằng nhiều góc nhìn — không chỉ một chỉ số

MAE

Sai lệch trung bình
“dự báo lệch bao
nhiêu?”

RMSE

Phạt sai số lớn
“điểm nào đang rất
lệch?”

Nhưng trực quan vẫn là bước kiểm tra
cuối cùng:



Hãy nhìn residual, outlier và phạm vi dữ liệu cùng với các chỉ số.

Công thức là công cụ đo; biểu đồ là công cụ chẩn đoán.



HCM-UTE

Kiểm tra tính hợp lý của mô hình

1

Đường có phù hợp xu hướng?

Scatter + đường hồi quy

2

Sai số có ngẫu nhiên?

Residual plot

3

Có điểm bất thường?

Outlier / leverage

4

Có đang dự báo quá xa?

Phạm vi quan sát



HCM-UTE

Kiểm tra residual: nhìn lỗi của mô hình

Mẫu residual	Dấu hiệu	Có thể gợi ý
Ngẫu nhiên quanh 0	Tương đối tốt	Cấu trúc tuyến tính có thể phù hợp
Có hình cong	Không tuyến tính	Cân nhắc biến đổi hoặc mô hình phi tuyến
Hình phễu	Phương sai thay đổi	Cân nhắc áp dụng thêm trọng số vào quá trình hồi qui
Cụm/đoạn riêng	Thiếu biến hoặc cấu trúc nhóm	Bổ sung biến / mô hình nhóm
Một vài điểm cực lớn	Outlier / leverage	Kiểm tra dữ liệu và ảnh hưởng điểm


Residual plot là một trong những cầu nối tự nhiên giữa mô hình thống kê và trực quan hóa dữ liệu.




HCM-UTE

Residual plot: hãy nhìn hình dạng của sai số


A - Ngẫu nhiên



B - Hình phễu



C - Có dạng cong



A - Tốt

Điểm rải quanh 0, không có hình mẫu rõ.

B - Phễu

Độ phân tán tăng khi X tăng
→ cần kiểm tra lại.

C - Cong


Residual tạo thành dạng cong
→ đường thẳng chưa kể hết
câu chuyện.




HCM-UTE

Các “bẫy” trực quan khi đọc đường hồi quy


Ngoại lệ kéo lệch đường



Độ phân tán mở rộng



Quan hệ cong



Ngoại suy: dễ gây hiểu nhầm



- 1 Ngoại lệ kéo lệch đường
- 2 Độ phân tán thay đổi theo X
- 3 Quan hệ thực tế có thể cong
- 4 Ngoại suy vượt vùng quan sát


➔ Một đường đẹp $\neq$ một mô hình luôn đúng.




HCM-UTE

Một dashboard hồi quy nên cho người dùng thấy gì?

1 · Xu hướng & điểm dữ liệu



3 · Phân bố kết quả



2 · Residual



4 · Chi tiết điểm đang chọn

Điểm chọn: 7 giờ/tuần

Dự báo ≈ 70.4

Sai số ước tính ≈ 2.6

01 · Xu hướng

Mối quan hệ X-Y và điểm dữ liệu

02 · Sai số

Residual có hình mẫu bất thường?

03 · Phân bố

Dữ liệu tập trung ở đâu?

04 · Điểm đang chọn

Click một điểm → cập nhật dự báo



Vì sao không nên dùng hồi quy tuyến tính cho phân loại nhị phân?

1. Dự báo có thể < 0 hoặc > 1

Một đường thẳng không bị giới hạn trong $[0, 1]$, trong khi xác suất phải nằm giữa 0 và 1.

2. Phương sai không phù hợp

Với $Y = 0/1$, độ biến thiên phụ thuộc vào p ; giả định đồng nhất phương sai dễ bị vi phạm.

3. Quan hệ xác suất-X không tuyến tính

Xác suất thường tăng chậm ở hai đầu và thay đổi mạnh quanh vùng quyết định.

$$\text{Logistic: } X \xrightarrow{\text{tuyến tính}} z \text{ (log-odds / logit)} \xrightarrow{\sigma(z)} p \in (0, 1) \rightarrow \text{Lớp}$$


Điểm quan trọng: logistic regression vẫn là mô hình tuyến tính theo tham số β , nhưng tuyến tính trên log-odds chứ không tuyến tính trực tiếp trên xác suất.



HCM-UTE

Chuyển từ dự báo giá trị sang dự báo xác suất

Cùng một bài toán, hai cách biến đổi đầu ra



Điểm khác biệt cốt lõi

Linear trả về một giá trị bất kỳ

Logistic trả về xác suất trong $(0,1)$

Từ đó mới có bước “chuyển xác suất $\rightarrow$ nhãn”.



HCM-UTE

4. Logistic Regression: mô hình xác suất cho phân loại

$$z = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$$

$$p = P(Y = 1|X) = 1 / (1 + e^{-z})$$

QUY TRÌNH 2 BƯỚC

Bước 1 : Dự báo xác suất

Mô hình trả $\hat{p} = 0.73$ nghĩa là xác suất ước lượng cho lớp $Y=1$ là 73% trong điều kiện dữ liệu đang xét.

Bước 2 : Chuyển thành lớp

Chọn threshold τ . Ví dụ $\tau=0.5$: $\hat{p} \geq 0.5 \rightarrow$ lớp 1;
 $\hat{p} < 0.5 \rightarrow$ lớp 0.



4. Logistic Regression: mô hình xác suất cho phân loại

Bài tập minh họa: Dự báo kết quả Học phần môn IDV

1. Bài toán

Giả sử một mô hình **Hồi quy Logistic** đã được huấn luyện để dự báo khả năng một sinh viên **Đậu (1)** hoặc **Rớt (0)** môn IDV (Tương tác dữ liệu trực quan 😊) dựa trên hai biến số:

- X_1 : Số giờ tự học trung bình mỗi tuần (giờ/tuần).
- X_2 : Điểm thi giữa kỳ (thang điểm 10).

Phương trình tổ hợp tuyến tính (z) tìm được từ dữ liệu huấn luyện có dạng:

$$z = -6.0 + 0.5X_1 + 0.8X_2$$

Xét dữ liệu của 3 sinh viên sau:

- **Sinh viên A**: Học $X_1 = 6$ giờ/tuần, điểm giữa kỳ $X_2 = 5.0$.
- **Sinh viên B**: Học $X_1 = 4$ giờ/tuần, điểm giữa kỳ $X_2 = 4.5$.
- **Sinh viên C**: Học $X_1 = 5$ giờ/tuần, điểm giữa kỳ $X_2 = 4.5$.

2. Yêu cầu

1. Tính giá trị z cho từng sinh viên.
2. Tính xác suất đậu $p = P(Y = 1|X)$ cho từng sinh viên bằng hàm Sigmoid.
3. Phân loại nhãn (**Đậu/Rớt**) với ngưỡng mặc định $\tau = 0.5$.
4. Đánh giá lại kết quả nếu Thầy Trí nâng ngưỡng đậu lên $\tau = 0.7$ để siết chặt chất lượng đầu ra



4. Logistic Regression: mô hình xác suất cho phân loại

Sinh viên A ($X_1 = 6, X_2 = 5.0$)

Bước 1 — Tính z_A :

$$z_A = -6.0 + 0.5(6) + 0.8(5.0) = -6.0 + 3.0 + 4.0 = 1.0$$

Bước 2 — Tính xác suất p_A :

$$p_A = \frac{1}{1 + e^{-z_A}} = \frac{1}{1 + e^{-1.0}} \approx \frac{1}{1 + 0.3679} \approx 0.731 \quad (73.1\%)$$

Bước 3 — Ra quyết định với $\tau = 0.5$:

Vì $p_A = 0.731 \geq 0.5 \implies$ Dự báo Đâu (Lớp 1).



4. Logistic Regression: mô hình xác suất cho phân loại

Sinh viên B ($X_1 = 4, X_2 = 4.5$)

Bước 1 — Tính z_B :

$$z_B = -6.0 + 0.5(4) + 0.8(4.5) = -6.0 + 2.0 + 3.6 = -0.4$$

Bước 2 — Tính xác suất p_B :

$$p_B = \frac{1}{1 + e^{-z_B}} = \frac{1}{1 + e^{-(-0.4)}} = \frac{1}{1 + e^{0.4}} \approx \frac{1}{1 + 1.4918} \approx 0.401 \quad (40.1\%)$$

Bước 3 — Ra quyết định với $\tau = 0.5$:

Vì $p_B = 0.401 < 0.5 \implies$ Dự báo Rớt (Lớp 0).



4. Logistic Regression: mô hình xác suất cho phân loại

Sinh viên C ($X_1 = 5, X_2 = 4.5$)

Bước 1 — Tính z_C :

$$z_C = -6.0 + 0.5(5) + 0.8(4.5) = -6.0 + 2.5 + 3.6 = 0.1$$

Bước 2 — Tính xác suất p_C :

$$p_C = \frac{1}{1 + e^{-z_C}} = \frac{1}{1 + e^{-0.1}} \approx \frac{1}{1 + 0.9048} \approx 0.525 \quad (52.5\%)$$

Bước 3 — Ra quyết định với $\tau = 0.5$:

Vì $p_C = 0.525 \geq 0.5 \implies$ Dự báo Đậu (Lớp 1).



4. Logistic Regression: mô hình xác suất cho phân loại

Sinh viên C ($X_1 = 5, X_2 = 4.5$)

Bước 1 — Tính z_C :

$$z_C = -6.0 + 0.5(5) + 0.8(4.5) = -6.0 + 2.5 + 3.6 = 0.1$$

Bước 2 — Tính xác suất p_C :

$$p_C = \frac{1}{1 + e^{-z_C}} = \frac{1}{1 + e^{-0.1}} \approx \frac{1}{1 + 0.9048} \approx 0.525 \quad (52.5\%)$$

Bước 3 — Ra quyết định với $\tau = 0.5$:


Vì $p_C = 0.525 \geq 0.5 \implies$ Dự báo Đâu (Lớp 1).



HCM-UTE

Sigmoid biến một tín hiệu thành xác suất có thể đọc được

Sigmoid: từ tín hiệu sang xác suất



Đọc đồ thị

$z \rightarrow$ âm vô cùng $\rightarrow p$ gần 0
 z quanh 0 $\rightarrow p$ gần 0.5
 $z \rightarrow$ dương vô cùng $\rightarrow p$ gần 1

τ là “quy tắc cắt” do người dùng / bài toán quyết định.


Thay vì hỏi “đúng hay sai?”, trước hết hãy hỏi “mô hình đang tin tới mức nào?”



HCM-UTE

Threshold là một nút điều khiển tương tác


Threshold τ



Kéo τ từ 0.1 $\rightarrow$ 0.9

τ thấp $\rightarrow$ dễ gán nhãn 1
 τ cao $\rightarrow$ khó gán nhãn 1

Threshold là “nút điều khiển” cách phân lớp



Những điểm có xác suất “ở giữa” là vùng cần người dùng quan sát kỹ.



HCM-UTE

Ví dụ 2 — Dự báo khả năng “đạt”

$$\text{logit}(p) = -4 + 0.8 \times \text{Giờ học}$$

Giờ học	$\hat{p}$	Lớp nếu $\tau=0.5$
2	0.039	Không đạt
4	0.231	Không đạt
5	0.500	Ranh giới
6	0.690	Đạt
8	0.961	Đạt

Threshold là một quyết định của hệ thống ứng dụng; không có lý do toán học bắt buộc phải luôn chọn 0.5.



HCM-UTE

Confusion Matrix và các chỉ số phân loại

		Dự đoán	
		Pred 0	Pred 1
Thực tế	True 0	TN	FP
	True 1	FN	TP

$$\text{Precision} = \text{TP}/(\text{TP}+\text{FP})$$

$$\text{Recall} = \text{TP}/(\text{TP}+\text{FN})$$

$$\text{F1} = 2\text{PR}/(\text{P}+\text{R})$$

$$\text{Accuracy} = (\text{TP}+\text{TN})/\text{N}$$



HCM-UTE

Confusion Matrix: nhìn sai–đúng bằng màu sắc

Ma trận nhầm lẫn

		Dự báo 0	Dự báo 1
Thật 0	82 TN	12 FP	
Thật 1	7 FN	99 TP	

XANH dự báo đúng

ĐỎ dự báo sai

Precision “Trong những mẫu mà mô hình gán 1, có bao nhiêu mẫu là mẫu đúng?”

Recall “Trong những trường hợp thật sự là 1, mô hình bắt được bao nhiêu?”

Điểm trực quan: màu sắc làm cho lỗi nổi lên ngay cả trước khi đọc công thức.



Threshold và trade-off trong phân loại

Threshold τ	Khuynh hướng phân loại	Tác động thường gặp
0.3	Dễ gán lớp 1 hơn	Recall lớp 1 có thể tăng; false positive có thể tăng
0.5	Cân bằng mặc định	Phù hợp khi chi phí hai loại lỗi tương đương
0.7	Khó gán lớp 1 hơn	Precision lớp 1 có thể tăng; false negative có thể tăng

Precision

Trong các dự đoán lớp 1, bao nhiêu là đúng?

Recall

Trong các mẫu thực sự là lớp 1, bắt được bao nhiêu?


F1

Trung bình điều hòa của precision và recall.



TƯƠNG TÁC

Threshold thay đổi $\rightarrow$ bức tranh chỉ số thay đổi theo



Khi τ tăng

Precision thường tăng vì mô hình “khó tính” hơn với nhãn 1.

Recall thường giảm vì nhiều trường hợp 1 bị bỏ sót.

Đây chính là điểm mà dashboard tương tác giúp người dùng tự khám phá trade-off.



HCM-UTE

DASHBOARD

Một thao tác → nhiều tín hiệu cập nhật

DASHBOARD · DỰ BÁO LOGISTIC

Threshold

0.50

Confusion Matrix

82	12
7	99

Phân bố xác suất dự báo

Precision

87%

Recall


93%

F1

90%

Kéo slider → thay đổi nhãn →
cập nhật confusion matrix +
Precision/Recall.

Đây là tư duy “model-in-the-loop”: trực quan hóa không chỉ để xem, mà để khám phá.





3. Linear Regression vs. Logistic Regression

Đặc điểm	Linear Regression	Logistic Regression
Biến mục tiêu	Liên tục: điểm, doanh thu, nhiệt độ...	Phân loại: 0/1 hoặc xác suất lớp
Đầu ra mô hình	Giá trị số $\hat{y} \in \mathbb{R}$	Xác suất $\hat{p} \in (0,1)$, sau đó có thể gán lớp
Hàm liên kết	Identity: $\hat{y} = \beta_0 + \beta X$	Sigmoid: $p = 1/(1+e^{-z})$
Hàm mất mát / ước lượng	Thường dùng SSE / MSE, OLS	Log-likelihood / binary cross-entropy
Trực quan đặc trưng	Đường thẳng phù hợp dữ liệu	Đường xác suất + threshold + confusion matrix
Ví dụ	Dự báo điểm số, giá trị liên tục, v.v..	Dự báo đạt / không đạt



Linear vs Logistic - nhìn bằng dữ liệu và đầu ra

Tiêu chí	LINEAR	LOGISTIC	Gợi ý trực quan
Đầu ra	Giá trị liên tục	Xác suất 0–1	→ Scatter + trend
Hình dạng	Đường thẳng	Đường cong chữ S	→ Sigmoid + threshold
Câu hỏi	“ $Y \approx$ bao nhiêu?”	“ $P(Y=1) =$ bao nhiêu?”	→ Xác suất theo từng điểm
Ví dụ	Điểm, doanh thu	Đạt/chưa đạt, có/không	→ Màu + ma trận nhầm lẫn



HCM-UTE

Xây dựng Logistic Regression

01 Chọn Y nhị phân

Ví dụ: Đạt = 1, Không đạt = 0

02 Chọn X

Giờ học, chuyên cần, số bài tập...

03 Tách dữ liệu

Train / validation / test

04 Fit model

Ước lượng β bằng maximum likelihood

05 Predict proba

Nhận $\hat{p}$ thay vì chỉ nhận lớp

06 Chọn threshold

Dựa trên mục tiêu và chi phí sai số

07 Evaluate

Confusion matrix + Precision/Recall/F1

08 Visualize

Xác suất, threshold, lỗi và nhóm dữ liệu



HCM-UTE

Trực quan hóa kết quả Logistic Regression

Thành phần	Nên thể hiện	Mục đích
Probability	ộ theo từng quan sát	Cho thấy mức độ chắc chắn tương đối
Threshold	Đường / giá trị τ	Giải thích cách biến xác suất thành lớp
Class distribution	Số lượng 0/1	Phát hiện mất cân bằng lớp
Confusion matrix	TN, FP, FN, TP	Nhìn trực tiếp các loại lỗi
Metric by threshold	Precision/Recall/F1 theo τ	Cho phép lựa chọn threshold có cơ sở


Trong một giao diện tương tác, người dùng có thể kéo threshold τ và quan sát đồng thời thay đổi của confusion matrix và Precision/Recall/F1.



HCM-UTE

TRỰC QUAN HÓA

Hai biến đầu vào: nhìn vùng dự báo trên mặt phẳng



Decision boundary

Đường biên chia mặt phẳng thành hai vùng dự báo.

Khi click / brush một điểm:

- Hiện thị xác suất của điểm
- Đổi màu theo nhãn
- Đưa điểm vào confusion matrix



HCM-UTE

TƯƠNG TÁC

Từ mô hình đến quyết định trên dashboard

Chọn dữ liệu

filter / brush

Quan sát xác suất

dot plot / sigmoid

Kéo threshold

slider τ

Kiểm tra lỗi

heatmap

Ra quyết định

hành động

Một dashboard tốt giúp người dùng đi qua chuỗi câu hỏi:

“Dữ liệu là gì?” → “Mô hình tin bao nhiêu?” → “Ngưỡng nào phù hợp?” →
“Sai ở đâu?”



HCM-UTE

GHI NHỚ

Dự báo + trực quan hóa

Mô hình giúp định lượng xu hướng và hỗ trợ tương tác ra quyết định.

Linear Regression

Dùng cho biến mục tiêu liên tục; trọng tâm: hệ số, residual, lỗi dự báo.

Logistic Regression

Dùng cho phân loại; trọng tâm: probability, logit (z), threshold và confusion matrix.

Mô hình tốt $\neq$ chỉ số đẹp $\rightarrow$ cần kiểm tra giả định + tổng quát hóa + diễn giải

Lưu ý: Hãy trực quan hóa cả dữ liệu, dự báo và sai số để người dùng hiểu mô hình đang làm gì.



BÀI TẬP VẬN DỤNG



HCM-UTE

BÀI TẬP VẬN DỤNG

Bối cảnh: Anh, Chị hãy tự thiết lập một dashboard theo dõi học tập để dự báo khả năng “Qua môn” hay không của chính mình trong môn tương tác dữ liệu trực quan.

Dữ liệu đầu vào

- Giờ học/tuần
- Tỷ lệ chuyên cần
- Số bài tập đã nộp
- Điểm giữa kỳ (giả xử là điểm TX 1)

Câu hỏi cần trả lời

1. Y có nên là nhị phân?
2. Có cần chuẩn hóa X?
3. Chọn threshold thế nào?
4. Metric nào là quan trọng?

Đầu ra dashboard

- Probability
- Predicted class
- Confusion matrix
- Precision/Recall/F1
- Threshold

Yêu cầu:

1. *Nêu lựa chọn mô hình và giải thích tại sao lựa chọn đó phù hợp với câu hỏi.*
2. *Tạo sinh dữ liệu (không ít hơn 500 mẫu) để minh họa cho giải pháp lựa chọn.*
3. *Tạo file .zip lưu trữ notebook và file .txt link dashboard.*



THANK YOU !